Conception d'un Jumeau Numérique Géométrique d'Aéroport par Apprentissage Profond

DeepSDF · Neural Fields · Fourier Features · SIREN

État de l'Art

Préparé par :

Haroun Joudi

Enseignante : Souhaila Arib

Matière : IA & Applications

Établissement : CY Tech **Date :** Mars 2026

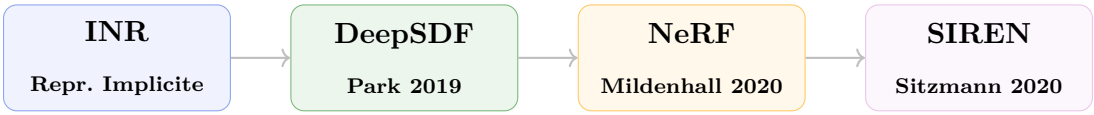

arXiv · NeurIPS · CVPR · ECCV · ICLR

Table des matières

Résumé **2**

1 Introduction **3**

2 Implicit Neural Representations et *inr2vec* (De Luigi et al., 2023) **3**

2.1 Le paradigme INR 3

2.2 Positionnement de l'article de De Luigi et al. dans la littérature INR 4

2.3 Apport scientifique et limites 5

3 DeepSDF (Park et al., 2019) **5**

3.1 Problème posé et formulation 5

3.2 Contributions de DeepSDF et portée de la méthode 6

3.3 Limites de l'article 7

4 NeRF (Mildenhall et al., 2020) **7**

4.1 Ce que modélise NeRF 7

4.2 Encodage positionnel et représentation des hautes fréquences 7

4.3 Apport scientifique et limites 8

5 SIREN (Sitzmann et al., 2020) **8**

5.1 Principe du modèle 8

5.2 Dérivées, régularité et équations aux dérivées partielles 9

5.3 Apport scientifique et limites 9

6 Discussion comparative **10**

7 Conclusion **11**

Résumé

Cette synthèse bibliographique examine quatre contributions structurantes pour les représentations neuronales implicites en 3D : le cadre général des *Implicit Neural Representations* (INR), *DeepSDF* de Park et al., *NeRF* de Mildenhall et al. et *SIREN* de Sitzmann et al. Le choix de ce corpus suit une logique analytique simple. Les INR définissent le paradigme continu ; DeepSDF en fournit une formulation géométrique explicite via la distance signée ; NeRF met en lumière le rôle de l'encodage positionnel pour les hautes fréquences ; SIREN montre enfin que la qualité d'une représentation implicite dépend aussi de la nature de ses activations et de ses dérivées.

Le rapport ne vise ni un panorama exhaustif de tous les travaux récents, ni une description applicative des phases ultérieures du projet. Deux références de contexte seulement sont conservées pour situer les articles sans diluer l'analyse : *Occupancy Networks*, voisin direct de DeepSDF en 2019, et *Fourier Features*, qui fournit un cadre de lecture au problème spectral mis en avant par NeRF. Le texte se concentre ainsi sur ce que les quatre articles *proposent*, sur la manière dont ils formulent leur problème, et sur ce qu'ils ont effectivement changé dans la littérature.

1 Introduction

Les représentations neuronales implicites remplacent une structure géométrique explicite par une fonction continue paramétrée par un réseau. En 3D, cette fonction peut coder une occupation, une distance signée, une densité volumique ou encore une couleur. Ce déplacement conceptuel a modifié en profondeur la reconstruction géométrique : la qualité spatiale ne dépend plus directement d'une grille volumique dense ni d'un maillage fixé à l'avance, mais de la capacité d'un modèle continu à approximer une forme.

Les quatre articles retenus permettent de lire ce champ selon quatre questions successives. D'abord, qu'implique le fait de traiter une forme comme une fonction ? Ensuite, comment apprendre directement une surface, comme dans DeepSDF ? Puis, pourquoi un MLP standard peine-t-il à restituer les hautes fréquences, et en quoi l'encodage positionnel de NeRF change-t-il ce point ? Enfin, que se passe-t-il lorsque l'architecture elle-même est conçue pour préserver des dérivées de qualité, comme le fait SIREN ? L'ordre du rapport suit cette logique.

2 Implicit Neural Representations et *inr2vec* (De Luigi et al., 2023)

2.1 Le paradigme INR

Une représentation neuronale implicite modélise une forme ou un signal par une fonction continue apprise. Dans le cas 3D, on peut ècrire de manière générale

$$f_\theta : \mathbb{R}^3 \to \mathbb{R}^k, \tag{1}$$

où la sortie peut représenter une probabilité d'occupation, une distance signée, une densité ou une autre quantité géométrique. Le point décisif n'est pas seulement la continuité du signal obtenu, mais le fait que la représentation est entièrement contenue dans les paramètres du modèle. Une forme n'est donc plus un objet discrétisé stocké explicitement ; elle devient une fonction interrogée à la demande.

Ce changement de paradigme modifie plusieurs propriétés fondamentales. La résolution n'est plus imposée par une maille fixe ; elle dépend du pas auquel on èvalue la fonction. La topologie n'a plus à être prédéfinie par une connectivité. Enfin, lorsque le modèle le permet, les gradients et autres dérivées deviennent directement accessibles. C'est ce qui explique l'intérêt croissant des INR dans des problèmes où l'on ne cherche pas seulement une forme visuellement plausible, mais une fonction géométrique exploitable.

Dans cette littérature, les INR se sont progressivement imposées comme un cadre général

de modélisation continue, au point de structurer aujourd'hui une large partie des *neural fields* en vision et en calcul scientifique [1]. Pour les formes 3D, des travaux précoces comme IM-NET ont joué un rôle important en montrant qu'un objet pouvait être appris comme champ implicite plutôt que comme structure discrète explicite [2].

Table 1 – Comparaison synthétique des représentations 3D

Aspect	**Voxels / maillages**	**Nuages de points**	**INR**
Stockage	Structure explicite de cellules ou de faces	Liste d'échantillons spatiaux	Poids d'un modèle continu
Résolution	Fixée par la discrétisation	Dépend du nombre de points	Libre à l'évaluation
Topologie	Implicite dans la structure choisie	Non connectée	Déduite du champ appris
Dérivées	Approchées numériquement	Non directement disponibles	Accessibles via le modèle

2.2 Positionnement de l'article de De Luigi et al. dans la littérature INR

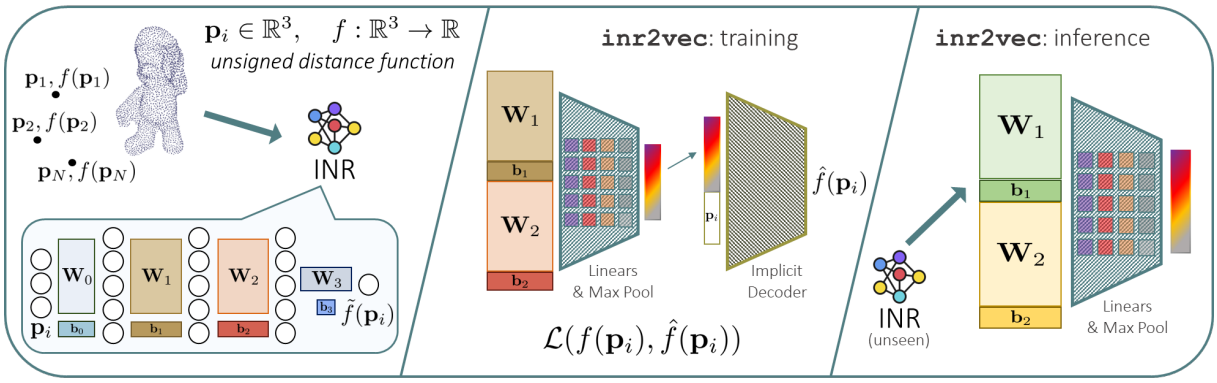

Figure 1 – Vue d'ensemble du cadre *inr2vec*, qui apprend un descripteur latent compact à partir d'une représentation implicite neurale en entrée.

L'article de De Luigi et al. [3] n'est pas un papier fondateur des INR au même sens que DeepSDF, NeRF ou SIREN. Son importance, dans un état de l'art, tient plutôt au fait qu'il déplace la question de recherche. Les auteurs ne cherchent plus seulement à apprendre une représentation implicite efficace pour une forme donnée ; ils s'intéressent à la manière dont une INR déjà apprise peut elle-même devenir l'entrée d'un pipeline de deep learning.

Le cadre proposé, *inr2vec*, calcule un descripteur latent compact pour une INR en une seule passe d'inférence, puis montre que ce descripteur peut être utilisé pour des tâches

aval comme la classification, le retrieval ou la segmentation. L'apport du papier est donc conceptuel autant que technique : il montre qu'une INR n'est pas seulement une fonction continue apprise pour représenter une forme, mais aussi un objet de calcul susceptible d'être comparé, compacté et réutilisé dans d'autres architectures.

Dans la littérature, ce positionnement prolonge la première vague des représentations implicites de formes, illustrée notamment par IM-NET et Occupancy Networks, qui avaient montré qu'une forme 3D pouvait être modélisée comme une fonction continue plutôt que comme une structure discrète [2, 4]. De Luigi et al. interviennent à un moment où ce paradigme est suffisamment stabilisé pour que l'on puisse apprendre non plus seulement *avec* des INR, mais *sur* des INR elles-mêmes.

2.3 Apport scientifique et limites

L'apport principal du papier est conceptuel. Les travaux fondateurs sur les INR s'intéressaient à la question « comment apprendre une forme comme fonction ». De Luigi et al. ajoutent une question nouvelle : « comment apprendre sur l'espace des fonctions ainsi obtenues » ? Cette inflexion marque une forme de maturité du domaine. Une INR n'est plus seulement une sortie finale ; elle devient un objet de calcul traitable en aval.

La limite du travail est symétrique de sa force. L'article suppose qu'une bonne INR est déjà disponible. Il ne traite donc ni l'acquisition de la donnée ni la stabilité de l'entraînement du modèle d'origine. Il faut le lire comme un prolongement du paradigme INR, pas comme une méthode concurrente à DeepSDF, NeRF ou SIREN.

3 DeepSDF (Park et al., 2019)

3.1 Problème posé et formulation

DeepSDF [5] propose de représenter une forme 3D par une fonction de distance signée continue. Pour un point $\mathbf{x}$, le modèle prédit une valeur telle que

$$f_\theta(\mathbf{x}) > 0 \text{ à l'extérieur}, \qquad f_\theta(\mathbf{x}) = 0 \text{ sur la surface}, \qquad f_\theta(\mathbf{x}) < 0 \text{ à l'intérieur}. \tag{2}$$

La surface est alors donnée par l'iso-surface d'équation $f_\theta(\mathbf{x}) = 0$. Cette formulation est forte parce qu'elle fait de la géométrie une quantité métrique continue plutôt qu'une simple frontière binaire.

Dans l'article, DeepSDF est appris comme un *auto-decoder*. Chaque forme d'entraînement est associée à un code latent $\mathbf{z}_i$, optimisé conjointement avec les poids du réseau. Le modèle apprend donc une fonction $f_\theta(\mathbf{z}_i, \mathbf{x})$, et l'objectif combine reconstruction des distances

signées et régularisation des codes latents :

$$\mathcal{L} = \sum_i \sum_{(\mathbf{x}_j, s_j) \in X_i} \ell\Big(f_\theta(\mathbf{z}_i, \mathbf{x}_j), s_j\Big) + \lambda \|\mathbf{z}_i\|_2^2. \tag{3}$$

Le papier insiste en outre sur une perte *clamped L1*, qui réduit l'influence des distances trop èloignées et concentre l'apprentissage dans le voisinage de la surface.

3.2 Contributions de DeepSDF et portée de la méthode

La contribution centrale de DeepSDF [5] est de montrer qu'une forme 3D peut être apprise comme une fonction continue de distance signée, paramétrée par un MLP profond. Ce choix va plus loin qu'une simple classification intérieur/extérieur : le modèle apprend une quantité métrique, dont l'iso-surface nulle définit la géométrie. Cette structure rend la représentation plus informative qu'un simple champ d'occupation et explique l'influence durable du papier dans la littérature des surfaces implicites.

L'autre apport du papier est d'avoir montré qu'une telle représentation combine compacité, qualité de reconstruction et interpolation dans l'espace latent. En pratique, DeepSDF devient rapidement une référence parce qu'il fournit une formulation claire et géométriquement cohérente du problème. Dans le paysage de 2019, il se distingue d'Occupancy Networks [4] par le fait qu'il apprend directement une distance signée plutôt qu'une probabilité d'occupation. Cette différence est importante : une frontière de décision permet de reconstruire une surface, mais une distance signée fournit en plus une structure locale de l'espace, potentiellement plus riche pour la géométrie.

Cette formulation explique la place durable de DeepSDF dans la littérature : le papier ne propose pas seulement une amélioration empirique, mais une définition géométriquement cohérente de la surface 3D comme zéro d'un champ de distance continu.

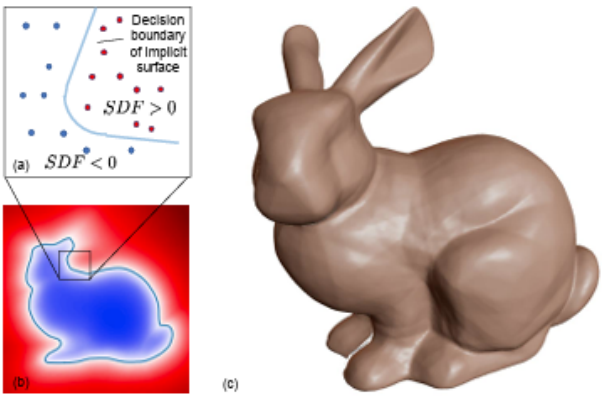

Figure 2 – Illustration de la représentation DeepSDF sur le Stanford Bunny.

3.3 Limites de l'article

Les limites de DeepSDF tiennent autant à sa formulation qu'à ses prérequis. L'apprentissage d'une distance signée fiable suppose un échantillonnage spatial très soigné et des données de surface propres. Le cadre original est en outre conçu pour des formes individuelles bien normalisées, chacune associée à un code latent propre. Enfin, comme d'autres MLP à activations usuelles, le modèle reste sensible au biais spectral : les composantes lisses sont apprises plus facilement que les hautes fréquences. C'est ce point qui rend l'apport de NeRF particulièrement important. Par ailleurs, la dépendance de DeepSDF à une supervision signée de bonne qualité explique l'intérêt de travaux ultérieurs comme SAL, qui cherchent à apprendre des surfaces implicites à partir de données brutes non signées [6].

4 NeRF (Mildenhall et al., 2020)

4.1 Ce que modélise NeRF

NeRF [7] n'apprend pas une surface explicite, mais un champ de radiance volumique continu. Le réseau prend en entrée une position 3D et une direction de vue, puis renvoie une couleur et une densité :

$$f_\theta(\mathbf{x}, \mathbf{d}) \to (\mathbf{c}, \sigma). \tag{4}$$

Le rendu d'une vue est ensuite obtenu par intégration volumique le long de chaque rayon. L'article s'inscrit donc d'abord dans une logique de synthèse de vues, et non dans une reconstruction géométrique au sens strict.

Si NeRF est devenu central dans la littérature INR, c'est pourtant moins pour sa sortie volumique que pour le verrou technique qu'il met en lumière. Les auteurs observent qu'un MLP alimenté par des coordonnées brutes apprend mal les hautes fréquences : textures fines, contours et détails géométriques restent flous. Le papier identifie donc un problème de capacité spectrale qui dépasse largement le seul cadre du rendu photoréaliste.

4.2 Encodage positionnel et représentation des hautes fréquences

Dans NeRF [7], l'encodage positionnel répond à une difficulté précise : un MLP standard qui reçoit directement des coordonnées spatiales tend à produire une approximation trop lisse et peine à modéliser les hautes fréquences. Les auteurs introduisent donc une projection des coordonnées dans une base de fonctions sinusoïdales de fréquences croissantes :

$$\gamma(p) = \Big(\sin(2^0\pi p), \cos(2^0\pi p), \ldots, \sin(2^{L-1}\pi p), \cos(2^{L-1}\pi p)\Big). \tag{5}$$

Cette transformation est appliquée aux coordonnées spatiales et, dans le papier, les auteurs utilisent typiquement $L = 10$ pour la position et $L = 4$ pour la direction de vue.

L'intérêt de ce mécanisme dépasse le cadre du rendu volumique. L'article montre empiriquement que la suppression de cet encodage dégrade fortement la qualité des détails géométriques et texturaux. C'est ce point qui a eu un impact durable : l'encodage positionnel est devenu une brique standard dès que l'on souhaite faire apprendre à un MLP des fonctions spatiales riches. Les travaux de Fourier Features ont ensuite fourni une lecture plus théorique de ce phénomène, en reliant l'amélioration observée à la question du biais spectral des réseaux [8].

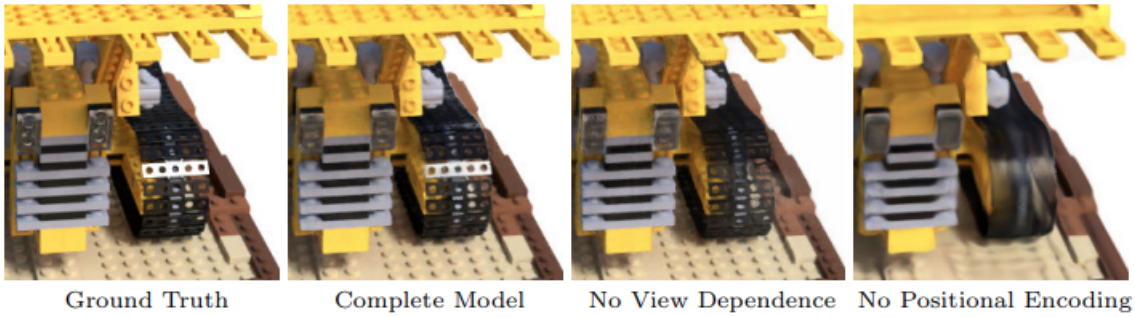

Figure 3 – Ablation de NeRF montrant l'importance de l'encodage positionnel pour la représentation des hautes fréquences géométriques et texturales.

4.3 Apport scientifique et limites

L'apport scientifique durable de NeRF est donc double. Le papier montre d'abord qu'un champ volumique continu peut surpasser les représentations explicites classiques pour la synthèse de vues. Mais il impose surtout l'encodage positionnel comme ingrédient central des INR modernes dès que la représentation des hautes fréquences devient cruciale. C'est la raison pour laquelle NeRF reste indispensable dans un état de l'art sur la 3D implicite, même lorsqu'on ne cherche pas à reproduire son pipeline complet de rendu.

Sa limite principale tient à la nature de sa sortie. NeRF modélise une densité et une radiance, pas une surface ni une distance à cette surface. La géométrie y est donc indirecte. L'article est fondamental pour comprendre *comment* enrichir un MLP implicite, mais non pour fournir à lui seul une formulation géométrique de référence comparable à DeepSDF.

5 SIREN (Sitzmann et al., 2020)

5.1 Principe du modèle

SIREN [9] part du même constat que NeRF, mais emprunte une voie beaucoup plus radicale. Au lieu d'enrichir les entrées avec des bases sinusoïdales tout en conservant des activations usuelles, l'article remplace la non-linéarité elle-même par une fonction

périodique :

$$\phi_i(\mathbf{x}) = \sin(\omega_0 \mathbf{W}_i \mathbf{x} + \mathbf{b}_i). \tag{6}$$

Ce choix impose une initialisation spécifique et une analyse des statistiques d'activation afin de garder des sorties bien conditionnées à travers la profondeur du réseau. La proposition est donc architecturale avant d'être applicative.

5.2 Dérivées, régularité et équations aux dérivées partielles

La force de SIREN [9] ne tient pas seulement à sa capacité à ajuster des signaux complexes. Elle tient surtout à la qualité des dérivées de la fonction apprise. Le papier part d'un constat fort : les architectures implicites classiques à base de ReLU peuvent approximer un signal, mais elles restituent mal ses gradients et ses dérivées d'ordre supérieur, alors même que ces quantités sont essentielles dans de nombreux problèmes physiques et géométriques.

L'introduction d'activations sinusoïdales et d'une initialisation adaptée change ce comportement. Les auteurs montrent que les SIREN sont bien plus adaptés à la représentation conjointe d'un signal et de ses dérivées, ce qui permet d'aborder non seulement la représentation d'images, de vidéos ou de sons, mais aussi la résolution de problèmes gouvernés par des équations aux dérivées partielles, comme les équations d'Eikonal, de Poisson, de Helmholtz ou des ondes.

Cet aspect place SIREN à un endroit particulier dans la littérature des INR. L'article ne propose pas seulement une meilleure activation ; il propose une autre manière de penser la fonction implicite, en insistant sur sa régularité différentielle. Cette orientation rejoint des travaux comme IGR [10], pour lesquels la qualité géométrique d'une surface implicite dépend directement du comportement du gradient et de la contrainte eikonale.

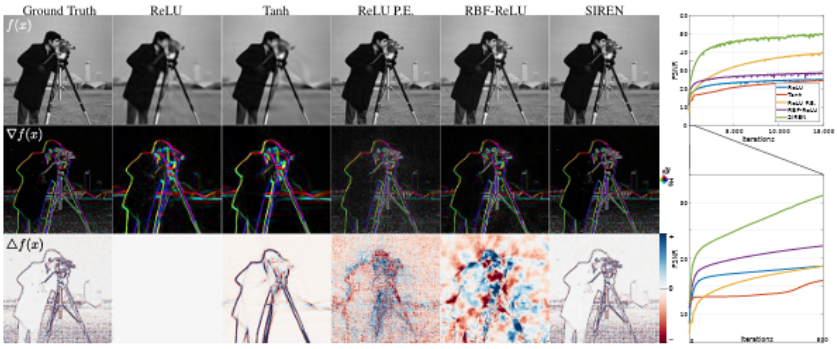

Figure 4 – Comparaison d'architectures implicites sur une image et sur ses dérivées dans SIREN.

5.3 Apport scientifique et limites

SIREN apporte à la littérature une leçon de fond : le choix de l'activation n'est pas un détail d'implémentation, mais une propriété structurelle de la représentation implicite.

En d'autres termes, tous les MLP continus ne se valent pas dès que l'on s'intéresse à des signaux riches en variations locales ou à des quantités définies par leurs dérivées.

La limite du modèle est d'être moins « plug-and-play » qu'un réseau à activations classiques. Son initialisation et son comportement numérique sont plus sensibles, ce qui demande davantage de soin. Le papier n'en reste pas moins essentiel parce qu'il montre qu'une INR peut être pensée comme fonction analytique exploitable, et non simplement comme surface implicite à extraire.

6 Discussion comparative

Table 2 – Lecture comparative des quatre articles principaux

Article	**Objet appris**	**Idée centrale**	**Apport et limite dominants**
De Luigi et al. (2023)	Embedding d'une INR	Traiter une INR comme une donnée d'entrée compacte	Ouvre l'apprentissage *sur* les INR ; suppose toutefois qu'une INR de qualité soit déjà disponible
Park et al. (2019)	Distance signée continue	Apprendre directement une surface comme zéro d'une SDF	Formulation géométrique forte ; dépend d'un bon èchantillonnage et de données propres
Mildenhall et al. (2020)	Champ de radiance volumique	Encodage positionnel pour les hautes fréquences	Apport méthodologique majeur ; la surface reste indirecte
Sitzmann et al. (2020)	INR à activations périodiques	Faire de l'activation un levier pour les dérivées	Excellente qualité analytique ; entraînement plus sensible qu'avec un MLP usuel

Ces quatre articles ne proposent pas quatre variantes concurrentes d'un même modèle. Ils se situent à des niveaux différents d'un même champ. De Luigi et al. formulent le problème de l'apprentissage *sur* les INR ; DeepSDF installe la distance signée comme représentation géométrique centrale ; NeRF résout le verrou spectral qui limite les MLP sur les détails fins ; SIREN réoriente enfin la discussion vers la qualité des gradients et des dérivées. Leur mise en regard permet donc de lire la littérature non comme une succession d'articles isolés, mais comme une décomposition progressive des problèmes essentiels des représentations implicites.

7 Conclusion

L'examen conjoint des quatre articles fait apparaître quatre dimensions complémentaires de la littérature sur les représentations neuronales implicites. Le paradigme INR pose l'idée d'une géométrie continue paramétrée par un réseau, et De Luigi et al. montrent que cette représentation peut elle-même devenir une entrée pour d'autres tâches d'apprentissage. DeepSDF donne à cette idée sa formulation géométrique la plus claire avec la distance signée continue. NeRF explique pourquoi la restitution des hautes fréquences impose un enrichissement spectral des entrées. SIREN montre enfin que la capacité d'une INR à représenter un signal ne peut pas être dissociée de sa capacité à en représenter proprement les dérivées. Pris ensemble, ces textes rendent lisible la structure même du domaine : continuité, géométrie, spectre et différentiabilité.

Références

[1] Y. Xie, T. Takikawa, P. P. Srinivasan, K. Keutzer, and D. B. Lindell, "Neural fields in visual computing and beyond," *Computer Graphics Forum*, vol. 41, no. 2, pp. 641–676, 2022. [Online]. Available : https://arxiv.org/abs/2111.11426

[2] Z. Chen and H. Zhang, "Learning implicit fields for generative shape modeling," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019. [Online]. Available : https://arxiv.org/abs/1812.02822

[3] L. De Luigi, A. Cardace, R. Spezialetti, P. Zama Ramirez, S. Salti, and L. Di Stefano, "Deep learning on implicit neural representations of shapes," in *International Conference on Learning Representations (ICLR)*, 2023. [Online]. Available : https://arxiv.org/abs/2302.05438

[4] L. Mescheder, M. Oechsle, M. Niemeyer, S. Nowozin, and A. Geiger, "Occupancy networks : Learning 3d reconstruction in function space," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019. [Online]. Available : https://arxiv.org/abs/1812.03828

[5] J. J. Park, P. Florence, J. Straub, R. Newcombe, and S. Lovegrove, "DeepSDF : Learning continuous signed distance functions for shape representation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 165–174. [Online]. Available : https://arxiv.org/abs/1901.05103

[6] M. Atzmon and Y. Lipman, "SAL : Sign agnostic learning of shapes from raw data," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020. [Online]. Available : https://arxiv.org/abs/1911.10414

[7] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng, "NeRF : Representing scenes as neural radiance fields for view synthesis," in *European Conference on Computer Vision (ECCV)*, 2020. [Online]. Available : https://arxiv.org/abs/2003.08934

[8] M. Tancik, P. P. Srinivasan, B. Mildenhall, S. Fridovich-Keil, N. Raghavan, U. Singhal, R. Ramamoorthi, J. T. Barron, and R. Ng, "Fourier features let networks learn high frequency functions in low dimensional domains," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Online]. Available : https://arxiv.org/abs/2006.10739

[9] V. Sitzmann, J. N. P. Martel, A. W. Bergman, D. B. Lindell, and G. Wetzstein, "Implicit neural representations with periodic activation functions," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Online]. Available : https://arxiv.org/abs/2006.09661

[10] A. Gropp, L. Yariv, N. Haim, M. Atzmon, and Y. Lipman, "Implicit geometric regularization for learning shapes," in *International Conference on Machine Learning (ICML)*, 2020. [Online]. Available : https://arxiv.org/abs/2002.10099